余逸凡 · 新加坡国立大学 DSML 2026

2026 届海外硕士

求职意向: AI 算法优化 · AI Infra · 算法研究

royyu0509@gmail.com · github.com/RoyYu0509

总结

个人背景: 从零实现 190M 参数 LLM 的模型架构, 训练, 与推理全栈 (Triton FA2 较朴素 attention 快 9.4×, DDP 扩展效率 86% , 自研推理引擎吞吐达 SGLang 同功能集 70%); 负责构建并评测 Agent 科研系统 (投稿 ICLR2027); 以第一作者在 JCP 发表 ML 不确定性量化方法.

教育背景

新加坡国立大学 — 理学硕士,数据科学与机器学习 2024.08 – 2026.07

· 专业课均分 **4.67/5.0**; 专业排名约 top 5%; 参与多项科研项目

· 专业课程：大语言模型, 高等线性代数, 可扩展计算, 数据库系统, 数据结构与算法, 大数据算法, 机器学习理论, 高等非线性优化

多伦多大学 — 高优荣誉理学学士, 统计学与经济学双专业,数学辅修 2020.09 – 2024.07

· 专业课均分 **3.92/4.0**; 专业排名约 top 5%; 入选院长名单 2022, 2023, 2024;

· 专业课程: 机器学习, 线性代数, 线性/非线性优化, 多元微积分, 概率论, 软件工程, 回归分析, 计算机架构, 商业金融, 中级(微/宏)观经济, 数据分析, 时序分析

项目经历

从零搭建+优化 LLM 训练与推理全栈, 独立开发者, 个人项目 2025.11 – 至今

不依赖 HF / vLLM 等训练推理框架，基于 PyTorch + Triton + NCCL 实现 LLM 训练与推理全栈

Repo: github.com/RoyYu0509/llm-stack

- **核心组件:** 从 0 手写 Llama 关键组件: C++ BPE Tokenizer / MHA / RMS Pre-Norm / RoPE / SwiGLU FFN / AdamW / top-p sampling, 转为 HF 官方 LlamaForCausalLM 后, fp32 下 logits 最大误差 2.2e-5.
- **Triton Flash Attention 算子优化:** 用 Nsight Systems 定位系统耗时瓶颈, 使用 Triton 实现 FlashAttention2 混合精度算子, 前向计算在 RTX 3090 Ti 下, 4K Attention kernel 显存 9.2 GB 降低至 49 MB, 较朴素 Attention 快 9.4×, 较 torch.compile 版快 3.0×, 显存与 PyTorch SDPA(flash) 持平.
- **基于 NCCL 手写多卡分布式训练:** 实现端到端分布式训练流水线,自研 NCCL DDP 通信重叠与梯度分桶机制；双卡 RTX 3090 扩展效率达 **86%**(吞吐达 27.7k tok/s), 性能追平 PyTorch 官方 DDP(27.6k tok/s), 显存额外开销仅 +3.7%.
- **自研推理框架:** 基于 Python AsyncIO 从零设计异步推理框架, 请求接收与推理异步并行推进, 调度策略可调 (每轮 prefill 准入数), 支持立即 / 排空(drain) 两种停机方式; FP32 下贪心输出与 HF generate 逐 token 一致.
- **连续批处理优化:** 引入 continuous batching 与批量 prefill，接入 flash-attn decode kernel 与 torch.compile；3090 Ti 单卡并发 32 吞吐由逐请求串行 47 tok/s 提升至 1,948 tok/s, TPOT 较基础版 CB 由 43 ms 降至 16 ms.
- **对标 SGLang:** 同机, 同 workload, 同功能集下, 自研推理引擎 32 条并发下, 吞吐达 SGLang 的 70%, 平均每输出 token 时间 (TPOT) 约为 16ms vs 11ms (SGLang).

科研经历

ICLR 2027 审核中：个性化科研 Agent Pipeline 的构建与评测 · NUS 资助 2026.05 – 2026.09

构建个性化 agentic 科研系统, 设计并实现 arXiv 论文召回 → idea 生成 → 理论核查 → 实验核查的四阶段 agent pipeline; 自建评测集与实验进行: 检索评测, 组件消融, 失败模式分析和 token 成本效益评估

Repo: github.com/RoyYu0509/ideation-claude

- **自建论文推荐评测集, 优化召回效果:** 从 12 周约 3 万篇 arXiv 新论文中均匀抽样 2,574 篇论文, 由专家逐篇根据相关性进行打分, 并使用该数据集对 3,000+ 种召回配置做 config search, 由交叉验证选定 RRF 融合最终配置; Precision@100 达 84%, 优于 SPECTER2 语义匹配(61%), BM25(51%), 随机基线(8.5%).
- **设计精排对照实验, 根据结果移除精排阶段:** 在上线配置产出的候选集上测试三种精排方法 cross-encoder 与 Sonnet 5.5 listwise 重排 (基础 / 带排序引导两种 prompt), 三种精排方法均降低了排序效果, nDCG@100 由 0.86 降至 0.68–0.71; 另外测试 Claude Code (Opus 5.5, 多 agents) 通读整周论文, 但在随机 3 位研究者画像上与上线配置的效果持平, 单次却需额外 15–29M tokens.
- **评测 idea 核查的效果:** 对 4 周 79 个候选问题逐级核查 (前提 / 理论推导 / 新颖性), 淘汰 49 个, 保留 30 个; 使用另一模型族在对齐专家打分后对所有候选问题进行盲评, 淘汰组 82% 为低分档, 保留组为 40%, 降低后选集中低质量问题比例.
- **工程设计:** 使用 orchestrator–worker 架构, 设计四阶段 agentic 科研工作流, 各阶段由 orchestrator agent 读取磁盘状态, 按固定流程调度 worker agents 或 agentic loop 负责当次科研任务; 设计问询机制让研究者可以中途介入 agentic loop 实时调整每一轮 worker agent 行为; 磁盘文件作为 shared memory 与 checkpoint, 中断后可从落盘状态恢复.

J. Comput. Phys. 顶刊一作: 提出创新校准方法让预测区间真正覆盖 95% 2025.04 – 2026.05

解决当前区间预测模型统计保证较差的问题, 实测 5 种 UQ 模型的 95% 预测区间, 覆盖率最低仅 12%; 提出事后校准方法 Local CP, 不重训原模型, 与模型结构, 任务无关, 使用一部分数据进行校准, 让预测区间保证目标覆盖率, 并让宽度自适应局部噪声.

Repo: github.com/RoyYu0509/Local-Conformal-Prediction-Torch
Paper: doi.org/10.1016/j.jcp.2026.114979

- **创新不确定性预测方法:** 提出 Local CP 方法, 在基础 CP 之上加一个轻量 quantile MLP, 学习局部噪声强度, 使高噪声域预测区间变宽, 平滑域预测区间变窄, 方法只依赖数据可交换性, 相比较基础 CP 无需额外数据, 与前置模型架构和任务无关
- **设计对照实验:** 5 种 baseline x 3 个 benchmark 中, Local CP 比标准 CP 能更精确地校准高噪声区覆盖率 0.76 提升至 0.94 (目标 0.95), 全域偏离度降低 77%, 预测区间宽度降低 30%, 显著改善局部的校准度和预测区间信息密度
- **测量方法额外计算开销与鲁棒性:** Local CP 训练耗时约为重训 baseline 模型的 1/3~1/20; 在校准数据降至原有 5%–30%时, 总覆盖率(高噪声区域+平滑区域)偏离仍显著低于标准 CP. 开源基于 PyTorch 的方法实现.

实习经历

战略分析实习生,Pacific Life Re(太平洋人寿再保险),新加坡 2024.10 – 2025.02

- **健康数据处理管线搭建:** 基于 JMDC 体检数据库, 搭建生存分析数据管线, 使用 SQL 从 Redshift 中关联多表, 在 800M 条记录中过滤保留相关 4.5M 条记录, 并使用 Polars lazy evaluation 完成 60+ features 的处理.
- **数据分析报告:** 为数据集写 5 项测试 (初始年份, 窗口连续性, 同年记录唯一性, 组间无泄露,准入年份) + 随机采样抽查, 测量连续窗口长度对于数据保留量的影响, 3 年增至 10 年, 成员保留率从约 76% 降到 31%, 可视化数据内容和关键特征统计值, 并向 director 汇报, 为后续生存分析项目提供可复用的全量数据工程管道.
- **半结构化数据采集:** 为公司可穿戴健康数据项目(越南)采集公开参照数据: 用 Python(requests / BeautifulSoup) 把 CDC NHANES 网页解析成 5.2 万行特征映射目录, 核对跨周期可用性(320 类表中仅 73 类全周期存在), 解析死亡关联文件产出生存分析标签.

论文发表

Yifan Yu, Cheuk Hin Ho, Yangshuai Wang. “A conformal prediction framework for uncertainty quantification in physics-informed neural networks.” ***Journal of Computational Physics***, 2026.

Yifan Yu, Jiale Linghu, Yangshuai Wang. “Arxidea: An Agentic System for Personalized Research Ideation and Evidence-Backed Verification.” ICLR 2027 under review.

Yifan Yu, Yangshuai Wang. “Geometry-preserving nudged elastic band and dimer methods under anisotropic force uncertainty.” arXiv:2605.24401.

技术栈

编程语言: Python · C++(了解) · R

LLM 系统: PyTorch · Triton · CUDA(了解) · NCCL · Nsight Systems · PyTorchProfiler · NumPy

Agent: Claude Code · Codex

Data & Cloud: SQL · Polars · PySpark · Pandas · AWS Redshift · SageMaker